

Analyse économétrique des déterminants de la valeur marchande des joueurs de football, Liga 2024/25

Raphaël ALCALA

1. Introduction

Le marché des transferts footballistiques est l'un des plus dynamiques de l'économie du sport, avec des montants dépassant plusieurs milliards d'euros chaque année, témoignant de l'importance économique considérable de ce secteur. Dans ce contexte, comprendre ce qui détermine la valeur marchande d'un joueur représente un enjeu majeur pour les clubs et les agents, une sous-évaluation pouvant conduire à des opportunités manquées, une surévaluation à des investissements non rentables.

La valeur marchande d'un joueur de football est un phénomène complexe, elle dépend à la fois de facteurs objectifs et quantifiables, les statistiques de performance, l'âge, le temps de jeu et de facteurs subjectifs et difficilement mesurables. Comme la notoriété médiatique, le potentiel futur, l'appartenance à un grand club, le pays du joueur.

Ce projet cherche à identifier ces déterminants en se concentrant sur une dimension différente : la variation de ces facteurs selon le poste occupé. Un avant-centre et un défenseur central n'ont pas le même rôle, ne génèrent pas les mêmes statistiques et ne sont pas évalués de la même façon sur le marché. Il est donc légitime de se demander si les mêmes facteurs expliquent leur valeur marchande respective.

Nous allons donc répondre à la problématique *“Dans quelle mesure les facteurs de performance influencent-ils la valeur marchande des joueurs de football, et ces effets varient-ils selon le poste occupé ?”*

Pour répondre à cette question, nous analysons un échantillon de 359 joueurs avec un minimum de 500 minutes jouées évoluant en Liga espagnole lors de la saison 2024/25. Ce championnat constitue un terrain d'étude pertinent, il regroupe certains des joueurs les plus valorisés au monde comme tout en incluant des profils plus modestes, offrant ainsi une grande variété de situations à analyser.

Notre approche repose sur l'estimation de huit modèles de régression distincts un par poste ou groupe de postes, en mobilisant des statistiques de performance spécifiques à chaque rôle. Nous vérifions les hypothèses économétriques classiques et les testeront leurs validité pour chaque modèle.

Pour ce faire nous allons nous organiser comme ceci: La section 2 présente les données utilisées et les choix méthodologiques opérés. La section 3 propose une analyse descriptive de l'échantillon. La section 4 présente les modèles économétriques et leurs résultats. La section 5 interprète et compare les résultats entre postes. La section 6 conclut et discute les limites du projet.

2. Présentation des données

2.1 Source des données

Les statistiques de performance ont été collectées sur plusieurs plateformes spécialisées de données footballistiques Sofascore, FBref, WhoScored et FotMob. Les valeurs marchandes proviennent de Transfermarkt, dont les estimations sont établies par une communauté d'experts. Les données ont été ensuite nettoyées sur Excel afin d'être prêtes à l'usage sur Python. C'est possiblement la partie qui a pris le plus de temps, il a fallu construire une base commune en harmonisant notamment l'orthographe des noms de joueurs entre les différentes sources, condition indispensable pour fusionner correctement les tables. Une fois cette base commune établie, les statistiques de chaque plateforme ont pu être ajoutées progressivement.

2.2 Échantillon

L'échantillon comprend 359 joueurs de Liga 24/25 répartis en 10 postes selon la classification Transfermarkt. Seuls les joueurs ayant disputé un minimum de 500 minutes ont été retenus, afin d'exclure les joueurs blessés ou peu utilisés dont les statistiques ne seraient pas représentatives.

2.3 Variable dépendante

La variable dépendante de ce projet est la valeur marchande des joueurs en millions d'euros, telle qu'estimée par Transfermarkt. Cette variable reflète le prix auquel un joueur pourrait être transféré sur le marché à un instant donné.

Cependant, la distribution brute de la valeur marchande présente une forte asymétrie, la majorité des joueurs ont une valeur modeste tandis que quelques superstars affichent des valeurs extrêmes. Utiliser cette variable violerait l'hypothèse de normalité des résidus nécessaire à la validité des estimations MCO.

Nous avons donc opté pour le logarithme naturel de la valeur marchande comme variable dépendante. Cette transformation normalise la distribution et permet d'interpréter les coefficients comme des variations en pourcentage de la valeur marchande pour une augmentation d'un écart-type de la variable explicative.

2.4 Variables explicatives

Les variables explicatives ont été sélectionnées selon leur pertinence économique pour le poste étudié.

L'âge est inclus comme variable de contrôle dans tous les modèles, un joueur plus âgé est généralement moins valorisé sur le marché en raison de son horizon de carrière plus court. Cependant, cette relation n'est pas linéaire la valeur marchande augmente d'abord avec l'âge jusqu'à un pic de maturité sportive, puis diminue. Pour capturer cette forme en cloche, nous introduisons un terme quadratique "Age_c²."

L'âge est centré autour de sa moyenne ($\text{Age}_c = \text{Age} - \text{moyenne}$) avant d'être mis au carré. Ce centrage est indispensable pour éliminer la multicollinéarité entre le terme linéaire et le terme quadratique.

Les variables spécifiques à chaque poste sont présentées en section 4.

3. Statistiques descriptives

3.1 Tableau descriptif


Poste	N	Moyenne	Écart-type	Min	Médiane	Max
Milieu offensif	24	23.3M	39.5M	0.8M	6.0M	180M
Ailier droit	29	20.3M	39.5M	0.6M	4.0M	200M
Ailier gauche	29	19.4M	36.1M	0.6M	5.0M	170M
Milieu central	54	16.9M	27.8M	0.9M	6.0M	140M
Avant-centre	52	12.6M	28.1M	0.4M	4.0M	180M
Milieu défensif	20	10.3M	16.6M	0.9M	4.5M	75M
Défenseur central	57	9.0M	13.7M	0.3M	4.0M	80M
Gardien de but	32	8.3M	8.8M	0.5M	5.5M	30M
Arrière gauche	28	7.1M	11.4M	1.0M	4.0M	60M
Arrière droit	27	6.9M	12.7M	0.3M	2.0M	65M

On observe d'abord une différence entre offensif et défensif marquante, les milieux offensifs (23.3M€), ailiers et milieux centraux affichent des moyennes supérieures à 15M€ tandis que les postes défensifs restent en dessous de 10M€.

L'écart important entre moyenne et médiane pour certains postes notamment pour les ailiers (20M€ vs 4-5M€) et milieux offensifs (23M€ vs 6M€) montre une forte asymétrie liée à la présence de joueurs à très haute valeur marchande ,ce qui justifie l'utilisation du logarithme comme variable dépendante.

Enfin, les gardiens présentent l'écart-type le plus faible (8.8M€) traduisant une distribution homogène au sein de ce poste, tandis que les ailiers et milieux offensifs affichent les dispersions les plus importantes.

3.2 Distribution de la valeur marchande par poste



Le graphique représente la distribution de la valeur marchande par poste sous forme de boîtes à moustaches, permettant de visualiser simultanément la médiane, les quartiles et les valeurs aberrantes pour chaque sous groupe.


La forte asymétrie des distributions confirme les observations du tableau descriptif. Pour la quasi-totalité des postes, la médiane est proche du bas de la boîte, la majorité des joueurs ont une valeur modeste tandis qu'une minorité tire la moyenne vers le haut. Cette asymétrie est particulièrement prononcée pour les ailiers dont les boîtes sont très comprimées malgré des valeurs maximales extrêmes (200M€ et 170M€).

Les valeurs aberrantes sont nombreuses pour les postes offensifs. Ces exceptions constituent une part irrationnelle de la valeur marchande que les statistiques ne peuvent pas capturer. Par exemple, "Lamine Yamal" est valorisé bien au-delà de ses statistiques en raison de son âge exceptionnel, de son potentiel futur et de son exposition médiatique mondiale.

À l'inverse, les postes défensifs présentent des distributions plus resserrées et homogènes, avec des valeurs maximales bien inférieures à celles des postes offensifs (65-80M€). Tout comme les gardiens qui affichent la distribution la plus compacte, avec très peu de valeurs aberrantes, ce qui est cohérent avec l'écart-type le plus faible (8.8M€).

Cette homogénéité pour ces postes explique en partie leur R^2 plus faible dans les modèles de régression la variance à expliquer est moins importante car les facteurs sont plus compliqués à quantifier qu'un attaquant par exemple.

3.3 Distribution de l'âge par poste



Le graphique ci-dessous représente la distribution des âges de l'ensemble des joueurs de l'échantillon, différenciée par poste sous forme d'histogramme empilé.


La distribution des âges suit une forme en cloche avec un pic entre 24 et 27 ans, période de maturité sportive où les joueurs combinent expérience et qualités athlétiques. On dénombre plus de 50 joueurs dans chacune de ces tranches, contre moins de 5 avant 19 ans et après 37 ans. Cette concentration justifie l'utilisation de l'âge centré dans nos modèles.

La forte présence de joueurs entre 28 et 31 ans, correspondant à des joueurs expérimentés en fin de pic de valeur marchande. Cette observation est cohérente avec l'effet âge négatif et universellement significatif observé dans tous nos modèles économétriques. Quel que soit le poste, une augmentation d'un écart-type de l'âge est associée à une diminution significative de la valeur marchande.

Quelques joueurs très jeunes (17-19 ans) constituent des cas atypiques, leur valeur marchande est exceptionnellement élevée malgré de jeunes statistiques, en raison de leur potentiel futur. Ce phénomène illustre une limite de nos modèles que les statistiques actuelles ne peuvent pas capturer.

Pour finir, les gardiens tendent à être plus âgés (entre 30 à 37 ans) reflétant la longévité caractéristique de ce poste où l'expérience et la lecture du jeu compensent le déclin athlétique, tandis que les ailiers sont concentrés dans les tranches les plus jeunes, leur jeu reposant davantage sur la vitesse et l'explosivité.

3.4 Relation entre xG90 et valeur marchande




Le graphique représente la relation entre les buts attendus par 90 minutes (xG90) et la valeur marchande des attaquants. La taille des points est proportionnelle aux minutes jouées.

Une relation positive globale est visuellement confirmée, les joueurs avec les xG90 les plus élevés tendent à avoir des valeurs marchandes plus importantes, cohérent avec les coefficients positifs et significatifs observés dans nos modèles.

Deux exceptions attirent l'attention, Comme énoncé auparavant, “Lamine Yamal” (200M€, xG90=0.35) illustre le phénomène de prime de potentiel, à 17 ans (au moment de la saison 24/25), sa valeur reflète son potentiel futur et son exposition médiatique plutôt que ses statistiques actuelles. De plus, “Vinicius Junior” (170M€, xG90=0.45) intègre quant à lui une prime de notoriété liée à son Ballon d'Or 2024.

De plus, les points les plus grands, titulaires avec plus de 2500 minutes, se concentrent dans la partie haute du graphique. Cela révèle que les joueurs les plus valorisés sont généralement aussi ceux qui jouent le plus, confirmant que la régularité est un signal de qualité fort sur le marché des transferts.

3.5 Valeur marchande moyenne par poste



Le graphique représente la valeur marchande moyenne par poste classée par ordre décroissant.

Comme on l'a vu dans les statistiques descriptives une différence offensif-défensif très net se dégage, les quatre postes les plus valorisés sont offensifs ou créateurs : milieu offensif (23.3M€), ailier droit (20.3M€), ailier gauche (19.4M€) et milieu central (16.9M€), tandis que les postes défensifs restent sous 10M€. Ce résultat confirme que la contribution offensive est systématiquement mieux valorisée sur le marché.

Le résultat le plus surprenant est la position du milieu offensif en tête, devant les ailiers et avant-centres. Cela s'explique par la présence de joueurs de classe mondiale et également que l'effectif est moins important que les autres, donc les valeurs extrêmes tirent fortement la moyenne vers le haut.

On peut également parler du poste de deuxième attaquant affichent la moyenne la plus faible (5.6M€) mais ce résultat est à nuancer, avec seulement 7 joueurs dans l'échantillon, cette moyenne est fortement influencée par les joueurs les moins valorisés et n'est pas vraiment représentative du poste. C'est pourquoi ce sous-groupe a été exclu de l'analyse économétrique.

Les avant-centres affichent une moyenne modeste (12.6M€) malgré leur rôle offensif central. La médiane à 4.0M€ confirme que la majorité sont des joueurs de complément, seule une minorité comme "Kylian Mbappé" (180M€) atteint des valorisations exceptionnelles.

4. Modèles économétriques

Les statistiques descriptives nous ayant permis d'identifier les grandes tendances du marché des transferts en Liga 24/25, nous procédons maintenant à l'estimation des modèles de régression par poste afin d'isoler les déterminants individuels de la valeur marchande en contrôlant l'ensemble des facteurs pertinents.

4.1 Méthodologie

Pour chaque poste, nous estimons un modèle de régression OLS de la forme :

$$\log(\text{Valeur marchande}) = \beta_0 + \beta_1 \text{Age}_c + \beta_2 \text{Age}_c^2 + \beta_3 X_3 + \dots + \beta_k X_k + \varepsilon$$

Où $X_3 \dots X_k$ représentent les variables spécifiques au poste. Les variables explicatives sont standardisées (moyenne=0, écart-type=1) avant estimation, permettant de comparer directement les coefficients entre variables.

La sélection des variables s'est réalisée en deux étapes. D'abord, nous avons retenu les variables économétriquement pertinentes pour chaque poste parmi l'ensemble des statistiques disponibles. Ensuite, les variables testées mais non significatives ou créant de la multicolinéarité ont été progressivement retirées jusqu'à obtenir le meilleur modèle possible.

Six tests économétriques sont systématiquement réalisés pour chaque modèle :

-Test de Jarque-Bera: Normalité des résidus

Ce test vérifie que les résidus du modèle suivent une loi normale, condition nécessaire pour que les tests t et F soient valides.

-H0 : les résidus sont normalement distribués

-H1 : les résidus ne sont pas normalement distribués

Résultat valide si $p > 0.05 \rightarrow$ on accepte H0

-Test de Durbin-Watson: Autocorrélation

Ce test vérifie l'absence de corrélation entre les résidus, condition nécessaire pour que les estimateurs MCO soient efficaces.

-H0 : absence d'autocorrélation

-H1 : présence d'autocorrélation

Résultat valide si DW proche de 2 (entre 1.5 et 2.5)

DW < 1.5 $\rightarrow$ autocorrélation positive

DW > 2.5 $\rightarrow$ autocorrélation négative

-Test de Breusch-Pagan: Hétéroscédasticité

Ce test vérifie que la variance des erreurs est constante, si elle ne l'est pas, les écarts-types sont biaisés et les tests t ne sont plus fiables.

-H0 : homoscédasticité, variance des erreurs constante

-H1 : hétéroscédasticité, variance non constante

Résultat valide si $p > 0.05 \rightarrow$ on accepte H0

-VIF: Multicolinéarité

Le VIF (Variance Inflation Factor) mesure le degré de corrélation entre les variables explicatives. Une forte corrélation entre variables rend les coefficients instables et non interprétables.

Formule : $VIF = 1 / (1 - R^2_j)$

Le VIF est calculé individuellement pour chaque variable explicative :

-VIF = 1 → aucune corrélation avec les autres variables

-1 < VIF < 5 → corrélation faible

-VIF > 5 → multicollinéarité problématique, variable à retirer

F-statistic: Validité globale du modèle

Ce test vérifie que le modèle dans son ensemble explique significativement la variable dépendante, autrement dit que le R^2 est significativement différent de zéro.

-H0 : $R^2 = 0$ → le modèle n'explique rien

-H1 : $R^2 \neq 0$

Résultat valide si $p < 0.05$ → on rejette H0

Tests t individuels: Significativité des variables

Ces tests vérifient que chaque variable explicative a un effet significatif sur la variable dépendante.

- H0 : $\beta_j = 0$ → la variable n'influence pas Y
- H1 : $\beta_j \neq 0$
- Résultat valide si $p < 0.05$ → on rejette H0
- Si $p > 0.05$ → la variable n'est pas significative
- Exception : Age_c² est conservé même non significatif par respect de la hiérarchie des polynômes — si Age_c² est dans le modèle, Age_c doit l'être aussi

4.2 Avant-centres

Variables retenues : xG90xA90, min, Age_c, Age_c² (n=52)

OLS Regression Results						
=====						
Dep. Variable:	log_val	R-squared:	0.790			
Model:	OLS	Adj. R-squared:	0.772			
Method:	Least Squares	F-statistic:	44.13			
Date:	Wed, 25 Mar 2026	Prob (F-statistic):	2.38e-15			
Time:	18:25:45	Log-Likelihood:	-43.807			
No. Observations:	52	AIC:	97.61			
Df Residuals:	47	BIC:	107.4			
Df Model:	4					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	1.6200	0.082	19.766	0.000	1.455	1.785
Age_c	-0.7421	0.093	-7.985	0.000	-0.929	-0.555
Age_c2	-0.1406	0.088	-1.596	0.117	-0.318	0.037
xG90xA90	0.8172	0.090	9.087	0.000	0.636	0.998
min	0.4557	0.086	5.326	0.000	0.284	0.628
=====						
Omnibus:	0.726	Durbin-Watson:		1.888		
Prob(Omnibus):	0.696	Jarque-Bera (JB):		0.822		
Skew:	0.179	Prob(JB):		0.663		
Kurtosis:	2.499	Cond. No.		1.72		

Breusch-Pagan
p-value:0.1856
VIF const: 1.00
VIF Age_c/:1.29
VIF Age_c2: 1.16
VIF xG90xA90 : 1.20
VIF min/1.09

Tests économétriques :

- JB $p=0.663$ normalité des résidus
- DW=1.888 pas d'autocorrélation
- BP $p=0.186$ homoscedasticité
- VIF max=1.29 pas de multicollinéarité
- F statistic $p=2.38e-15$ modèle globalement significatif
- Significativité : Age_c, xG90xA90, min $p<0.05$; Age_c² limite ($p=0.117$) conservé hiérarchie polynômes

Le modèle avant-centres présente le meilleur R^2 de l'étude (0.790). Ce résultat s'explique par la nature du poste, la performance d'un avant-centre est directement quantifiable via ses statistiques offensives comme les buts , les buts attendus (xG) ,les passes décisives et les passes décisives attendues (xA), ce qui facilite la modélisation. En l'occurrence la variable la plus significative est "xG90xA90" (+0.817), c'est à dire le nombre de buts et de passes décisives attendues par match , ce qui permet de capturer la performance offensive globale.

4.3 Ailiers

Variables retenues : Age_c, Age_c², Dribble, xA90, xG90, min

OLS Regression Results						
=====						
Dep. Variable:	log_val	R-squared:	0.772			
Model:	OLS	Adj. R-squared:	0.745			
Method:	Least Squares	F-statistic:	36.12			
Date:	Thu, 26 Mar 2026	Prob (F-statistic):	1.05e-16			
Time:	03:25:39	Log-Likelihood:	-60.703			
No. Observations:	58	AIC:	135.4			
Df Residuals:	51	BIC:	149.8			
Df Model:	6					
Covariance Type:	HC3					
=====						
	coef	std err	z	P> z	[0.025	0.975]

const	1.8932	0.105	18.033	0.000	1.687	2.099
Age_c	-0.6018	0.161	-3.748	0.000	-0.916	-0.287
Age_c2	-0.3107	0.166	-1.867	0.062	-0.637	0.015
Dribble	0.3151	0.152	2.072	0.038	0.017	0.613
xA90	0.4321	0.130	3.317	0.001	0.177	0.687
xG90	0.3441	0.094	3.677	0.000	0.161	0.528
min	0.1769	0.081	2.185	0.029	0.018	0.336
=====						
Omnibus:	3.329	Durbin-Watson:	2.154			
Prob(Omnibus):	0.189	Jarque-Bera (JB):	2.756			
Skew:	0.532	Prob(JB):	0.252			
Kurtosis:	3.083	Cond. No.	2.79			

Breusch-Pagan p-value:
0.0156

VIF const : 1.00

VIF Age_c : 1.31

VIF Age_c2 : 1.14 VIF

Dribble: 2.19

VIF xA90 : 1.31

VIF xG90 : 1.14

VIF min : 1.67

Tests économétriques :

- JB $p=0.252$ normalité des résidus
- DW=2.154 pas d'autocorrélation
- BP $p=0.016$ hétéroscédasticité détectée: correction HC3 appliquée
- VIF max=2.19 pas de multicollinéarité
- F $p=1.05e-16$ modèle globalement significatif
- Significativité : Age_c, xA90, xG90, Dribble, min $p<0.05$, Age_c² limite ($p=0.062$) conservé hiérarchie polynômes

Le modèle ailiers présente un $R^2=0.772$, comme pour les avant-centres, la performance d'un ailier reste relativement quantifiable via ses statistiques offensives. La variable la plus significative est xA90 (+0.432), c'est-à-dire les passes décisives attendues par 90 minutes, suivi de xG90 (+0.3441), c'est à dire le nombre de buts attendus par match. Le dribble (+0.315) est également une variable importante à ce poste.

4.4 Milieux offensifs et centraux

Nous avons regroupés les milieux offensifs et centraux pour deux raisons. D'abord, le faible effectif des milieux offensifs (n=24) seuls ne permettait pas une estimation robuste avec plusieurs variables explicatives. Ensuite, les deux postes partagent une logique économique commune, leur valeur marchande repose principalement sur la capacité à créer et à faire progresser le jeu vers l'avant.

Variables retenues : Age_c, Age_c², xG90xA90, Accurate final third pass, Accurate passes %

OLS Regression Results						
=====						
Dep. Variable:	log_val	R-squared:	0.643			
Model:	OLS	Adj. R-squared:	0.618			
Method:	Least Squares	F-statistic:	25.90			
Date:	Thu, 26 Mar 2026	Prob (F-statistic):	7.34e-15			
Time:	03:28:16	Log-Likelihood:	-91.055			
No. Observations:	78	AIC:	194.1			
Df Residuals:	72	BIC:	208.2			
Df Model:	5					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	2.0245	0.092	22.092	0.000	1.842	2.207
Age_c	-0.6045	0.094	-6.437	0.000	-0.792	-0.417
Age_c2	-0.2607	0.101	-2.579	0.012	-0.462	-0.059
xG90xA90	0.3343	0.098	3.423	0.001	0.140	0.529
Accurate final third pass	0.5830	0.114	5.131	0.000	0.356	0.810
Accurate passes %	0.3498	0.112	3.132	0.003	0.127	0.573
=====						
Omnibus:	0.284	Durbin-Watson:	1.343			
Prob(Omnibus):	0.868	Jarque-Bera (JB):	0.120			
Skew:	-0.096	Prob(JB):	0.942			
Kurtosis:	3.013	Cond. No.	2.09			
=====						

Breusch-Pagan p=0.212
VIF const=1.00
VIF Age_c=1.05
VIF Age_c2=1.22
VIF xG90xA90=1.14 VIF
Accurate final third
pass=1.54
VIF Accurate passes%
=1.49

Tests économétriques :

- JB p=0.942 normalité des résidus
- DW=1.343 pas d'autocorrélation
- BP p=0.212 homoscédasticité
- VIF max=1.54 pas de multicolinéarité
- F p=7.34e-15 modèle globalement significatif
- Significativité : toutes les variables significatives p<0.05

Le modèle MO+MC présente un $R^2=0.643$. La performance d'un milieu est plus difficile à quantifier que celle d'un attaquant, elle ne se résume pas à des statistiques offensives directes mais à la qualité de la construction du jeu, ce qui explique un R^2 plus modéré. La variable la plus significative est "Accurate final third pass" (+0.583), c'est-à-dire le nombre de passes précises effectuées dans le dernier tiers du terrain. xG90xA90 (+0.334) et Accurate passes % (+0.350) complètent le modèle, confirmant que la contribution offensive et la qualité de distribution sont également valorisées.

4.5 Milieux centraux

Variables retenues : Age_c, Age_c², xA90, Accurate passes

OLS Regression Results						
=====						
Dep. Variable:	log_val	R-squared:	0.649			
Model:	OLS	Adj. R-squared:	0.620			
Method:	Least Squares	F-statistic:	22.60			
Date:	Thu, 26 Mar 2026	Prob (F-statistic):	1.27e-10			
Time:	03:29:38	Log-Likelihood:	-56.831			
No. Observations:	54	AIC:	123.7			
Df Residuals:	49	BIC:	133.6			
Df Model:	4					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	2.0393	0.099	20.595	0.000	1.840	2.238
Age_c	-0.7348	0.108	-6.797	0.000	-0.952	-0.518
Age_c2	-0.0729	0.115	-0.636	0.527	-0.303	0.157
xA90	0.2106	0.110	1.915	0.061	-0.010	0.432
Accurate passes	0.6793	0.107	6.351	0.000	0.464	0.894
=====						
Omnibus:	2.558	Durbin-Watson:		1.332		
Prob(Omnibus):	0.278	Jarque-Bera (JB):		2.396		
Skew:	0.500	Prob(JB):		0.302		
Kurtosis:	2.746	Cond. No.		1.81		

Breusch-Pagan p=0.469
VIF const=1.00
VIF Age_c=1.19 VIF
Age_c2=1.34 VIF
xA90=1.23
VIF Accurate
passes=1.17

Tests économétriques :

- JB p=0.302 normalité des résidus
- DW=2.590 pas d'autocorrélation
- BP p=0.469 homoscédasticité
- VIF max=1.34 pas de multicolinéarité
- F p=1.27e-10 modèle globalement significatif
- Significativité : Age_c p=0.000, Accurate passes p=0.000 ,xA90 limite p=0.061, Age_c² conservé hiérarchie polynômes

Le modèle milieux centraux présente un $R^2=0.649$. On remarque encore une fois que la valeur des milieux est plus difficile à capter que celle des attaquants. La variable la plus significative est "Accurate passes" (+0.679), c'est-à-dire le nombre de passes précises. xA90 (+0.211) est retenu malgré une significativité limite (p=0.061) car la contribution offensive reste une dimension pertinente pour ce poste.

4.6 Milieux défensifs

Contrairement aux milieux offensifs qui ont été regroupés avec les milieux centraux, les milieux défensifs ont été traités séparément malgré leur faible effectif (n=20). Ce choix s'explique par la nature différente de ce poste, un milieu défensif se distingue fondamentalement d'un milieu central par son rôle. Les variables significatives pour les MC ne l'étaient pas pour les MDC, confirmant que les deux postes obéissent à des logiques de valorisation distinctes sur le marché. Un regroupement MC+MDC aurait donc introduit une hétérogénéité non justifiée dans le modèle.

Variables retenues : Age_c, Age_c², % duels won, Accurate passes

OLS Regression Results						
=====						
Dep. Variable:	log_val	R-squared:	0.679			
Model:	OLS	Adj. R-squared:	0.594			
Method:	Least Squares	F-statistic:	7.948			
Date:	Thu, 26 Mar 2026	Prob (F-statistic):	0.00120			
Time:	03:30:47	Log-Likelihood:	-19.233			
No. Observations:	20	AIC:	48.47			
Df Residuals:	15	BIC:	53.44			
Df Model:	4					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	1.6240	0.163	9.936	0.000	1.276	1.972
Age_c	-0.4757	0.195	-2.445	0.027	-0.890	-0.061
Age_c2	-0.1498	0.194	-0.771	0.453	-0.564	0.264
% duels won	0.3491	0.184	1.899	0.077	-0.043	0.741
Accurate passes	0.4608	0.192	2.403	0.030	0.052	0.869
=====						
Omnibus:	0.257	Durbin-Watson:		1.508		
Prob(Omnibus):	0.880	Jarque-Bera (JB):		0.060		
Skew:	-0.115	Prob(JB):		0.971		
Kurtosis:	2.863	Cond. No.		1.92		

Breusch-Pagan
p=0.790
VIF const= 1.00
VIF Age_c= 1.42
VIF Age_c2= 1.41 VIF
% duels
won= 1.27
VIF Accurate passes=
1.38

Tests économétriques :

- JB p=0.971 normalité excellente
- DW=1.508 pas d'autocorrélation
- BP p=0.790 homoscédasticité
- VIF max=1.42 pas de multicollinéarité
- F p=0.001 modèle globalement significatif
- Significativité : Age_c p=0.027 , Accurate passes p=0.030 , % duels won limite p=0.077, Age_c² conservé hiérarchie polynômes

Le modèle MDC présente un R²=0.679. Le faible effectif (n=20) constitue une limite reconnue de ce modèle, l'écart entre R² (0.679) et R² ajusté (0.594) en témoigne. Ce résultat est donc à interpréter avec précaution. La performance d'un milieu défensif est par ailleurs difficile à quantifier, des qualités essentielles comme le positionnement défensif ou la lecture du jeu ne sont pas captables par les statistiques disponibles. La variable la plus significative est "Accurate passes" (+0.461), MDC est valorisé non seulement pour sa capacité à récupérer le ballon mais aussi pour sa qualité de relance après récupération.

4.7 Défenseurs centraux

Variables retenues : Age_c, Age_c², Total duels won, Dribbled past

OLS Regression Results						
=====						
Dep. Variable:	log_val	R-squared:	0.488			
Model:	OLS	Adj. R-squared:	0.448			
Method:	Least Squares	F-statistic:	12.37			
Date:	Thu, 26 Mar 2026	Prob (F-statistic):	3.87e-07			
Time:	03:31:49	Log-Likelihood:	-75.642			
No. Observations:	57	AIC:	161.3			
Df Residuals:	52	BIC:	171.5			
Df Model:	4					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	1.3807	0.127	10.914	0.000	1.127	1.635
Age_c	-0.6218	0.133	-4.684	0.000	-0.888	-0.355
Age_c2	-0.0650	0.134	-0.486	0.629	-0.333	0.203
Total duels won	0.8082	0.171	4.720	0.000	0.465	1.152
Dribbled past	-0.3575	0.170	-2.106	0.040	-0.698	-0.017
=====						
Omnibus:	1.666	Durbin-Watson:	1.818			
Prob(Omnibus):	0.435	Jarque-Bera (JB):	1.457			
Skew:	0.246	Prob(JB):	0.483			
Kurtosis:	2.391	Cond. No.	2.28			

Breusch-Pagan p=0.541
VIF const=1.00
VIF Age_c=1.10
VIF Age_c2=1.12 VIF
Total duels won=1.83
VIF Dribbled past=1.80

Tests économétriques :

- JB p=0.483 normalité des résidus
- DW=1.818 pas d'autocorrélation
- BP=p 0.541 homoscédasticité
- VIF max=1.83 pas de multicollinéarité
- F p=3.87e-07 modèle globalement significatif
- Significativité : Age_c p=0.000 , Total duels won p=0.000 , Dribbled past p=0.040 ,Age_c² conservé hiérarchie polynômes

Le modèle défenseurs centraux présente un R²=0.488, le plus faible des postes de champ. Ce résultat s'explique directement par la nature du poste, contrairement aux attaquants, la performance d'un défenseur central est très difficile à quantifier. Des qualités essentielles comme le positionnement, le leadership ou la communication n'apparaissent dans aucune statistique disponible. La variable la plus significative est "Total duels won" (+0.808), un DC qui remporte ses duels est logiquement plus valorisé. "Dribbled past" présente un coefficient négatif (-0.358), se faire dribbler pénalise la valeur marchande, ce qui est économiquement cohérent pour un poste dont le rôle premier est de ne pas se laisser éliminer.

4.8 Latéraux

Variables retenues : Age_c, Age_c², Key passes

OLS Regression Results						
=====						
Dep. Variable:	log_val		R-squared:	0.483		
Model:	OLS		Adj. R-squared:	0.453		
Method:	Least Squares		F-statistic:	15.91		
Date:	Thu, 26 Mar 2026		Prob (F-statistic):	1.98e-07		
Time:	03:33:45		Log-Likelihood:	-63.295		
No. Observations:	55		AIC:	134.6		
Df Residuals:	51		BIC:	142.6		
Df Model:	3					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	1.2675	0.107	11.835	0.000	1.052	1.483
Age_c	-0.6616	0.107	-6.164	0.000	-0.877	-0.446
Age_c2	-0.0710	0.108	-0.656	0.515	-0.288	0.146
Key passes	0.3508	0.108	3.243	0.002	0.134	0.568
=====						
Omnibus:	4.590		Durbin-Watson:	1.730		
Prob(Omnibus):	0.101		Jarque-Bera (JB):	3.530		
Skew:	0.541		Prob(JB):	0.171		
Kurtosis:	3.609		Cond. No.	1.16		

Breusch-Pagan p=0.447
VIF const=1.00
VIF Age_c=1.00 VIF
Age_c2=1.02 VIF Key
passes=1.02

Tests économétriques :

- JB p=0.171 normalité des résidus
- DW=1.730 pas d'autocorrélation
- BP p=0.447 homoscédasticité
- VIF max=1.02 absence totale de multicollinéarité — meilleur résultat de l'étude
- F p=1.98e-07 modèle globalement significatif
- Significativité : Age_c p=0.000 , Key passes p=0.002 , Age_c² conservé hiérarchie polynômes

Le modèle latéraux présente un R²=0.483. Le résultat le plus remarquable est que seule une variable offensive s'avère significative, "Key passes" (+0.351), c'est-à-dire les passes clés menant directement à une occasion de but. Ce résultat est surprenant étant donné qu'aucune variable défensive n'a été significative, ce qui montre encore une fois la difficulté à capter la valeur défensive.

4.9 Gardiens de but

Variables retenues : Age_c, Age_c², CS

OLS Regression Results						
=====						
Dep. Variable:	log_val	R-squared:	0.534			
Model:	OLS	Adj. R-squared:	0.484			
Method:	Least Squares	F-statistic:	10.68			
Date:	Thu, 26 Mar 2026	Prob (F-statistic):	7.51e-05			
Time:	03:34:45	Log-Likelihood:	-40.674			
No. Observations:	32	AIC:	89.35			
Df Residuals:	28	BIC:	95.21			
Df Model:	3					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	1.4363	0.163	8.811	0.000	1.102	1.770
Age_c	-0.7727	0.181	-4.273	0.000	-1.143	-0.402
Age_c2	-0.1050	0.176	-0.597	0.555	-0.465	0.255
CS	0.6603	0.172	3.833	0.001	0.307	1.013
=====						
Omnibus:	4.027	Durbin-Watson:		2.745		
Prob(Omnibus):	0.134	Jarque-Bera (JB):		2.527		
Skew:	0.567	Prob(JB):		0.283		
Kurtosis:	3.779	Cond. No.		1.60		
=====						

Breusch-Pagan p=0.258
VIF const=1.00
VIF Age_c=1.23 VIF
Age_c2=1.16 VIF
CS=1.12

Tests économétriques :

- JB p=0.283 normalité des résidus
- DW=2.745 pas d'autocorrélation
- BP p=0.258 homoscédasticité
- VIF max=1.23 pas de multicolinéarité
- F p=7.51e-05 modèle globalement significatif
- Significativité : Age_c p=0.000 ,CS p=0.001 ,Age_c² conservé hiérarchie polynômes

Le modèle gardiens présente un $R^2=0.534$. Seulement deux variables suffisent à expliquer 53.4% de la variance. Aucune autre statistique individuelle n'est ressortie significative, ce qui illustre la difficulté à quantifier la performance d'un gardien, des qualités essentielles comme les réflexes, le placement ou la gestion de son équipe ne sont pas captables par les statistiques disponibles. La seule variable de performance significative est "CS" (+0.660), c'est-à-dire le nombre de fois où l'équipe n'a pas pris de but. cette statistique capturant à la fois la performance individuelle et la régularité sur la saison. L'effet âge est le plus fort de tous les postes (-0.773), la valeur d'un gardien chute plus rapidement avec l'âge que pour n'importe quel autre poste, la valeur marchande d'un gardien dépend largement de facteurs non quantifiables que notre modèle ne peut pas capturer.

5. Interprétation et comparaison des résultats

5.1 Vue d'ensemble des modèles

Le tableau ci-dessous résume les performances des huit modèles estimés :

Poste	n	R ²	R ² ajusté	Variable clé
Avant-centres	52	0.790	0.772	xG90xA90 (+0.817)
Ailiers	58	0.772	0.745	xA90 (+0.432)
MO+MC	78	0.643	0.618	Accurate final third (+0.583)
MC seul	54	0.649	0.620	Accurate passes (+0.679)
MDC	20	0.679	0.594	Accurate passes (+0.461)
DC	57	0.488	0.448	Total duels won (+0.808)
Latéraux	55	0.483	0.453	Key passes (+0.351)
Gardiens	32	0.534	0.484	CS (+0.660)

5.2 Différence offensif-défensif

Le résultat le plus marquant est la différence claire entre postes offensifs et défensifs en termes de pouvoir explicatif. Les modèles attaquants et ailiers atteignent des R² supérieurs à 0.77, tandis que les modèles défensifs restent sous 0.55. Ce résultat s'explique par la nature même des statistiques disponibles, la performance offensive est directement quantifiable, tandis que la performance défensive dépend de dimensions qu'on ne peut pas capturer avec les statistiques disponibles.

5.3 L'âge, facteur universel

L'âge est la seule variable significative dans tous les modèles sans exception. Son effet est systématiquement négatif, une augmentation d'un écart-type de l'âge centré est associée à une diminution de la valeur marchande allant de -0.476 pour les MDC à -0.773 pour les gardiens.

Cette différence révèle une asymétrie importante selon les postes. Les ailiers subissent un effet âge fort (-0.614) car leur jeu repose principalement sur des qualités athlétiques comme la vitesse et l'explosivité qui déclinent rapidement. Les gardiens subissent l'effet le plus fort (-0.773), leur valeur marchande chute rapidement car au-delà d'un certain âge les réflexes et l'agilité ne peuvent plus être compensés. À l'inverse, les MDC subissent l'effet le plus faible (-0.476) car leurs qualités principales, lecture du jeu, expérience, positionnement, se déprécient bien moins vite avec l'âge.

6. Conclusion et limites

6.1 Conclusion générale

Ce projet avait pour objectif d'identifier les déterminants de la valeur marchande des joueurs de football en Liga 24/25 et d'analyser si ces déterminants varient selon le poste. En estimant huit modèles de régression distincts sur un échantillon de 359 joueurs, nous avons obtenu plusieurs résultats significatifs.

Les postes offensifs sont mieux modélisés que les postes défensifs, les avant-centres ($R^2=0.790$) et ailiers ($R^2=0.772$) présentent les pouvoirs explicatifs les plus élevés, tandis que les défenseurs centraux ($R^2=0.488$) et latéraux ($R^2=0.483$) affichent les plus faibles. Ce résultat confirme que la performance offensive est plus directement quantifiable que la performance défensive.

L'âge est le seul facteur universellement significatif dans tous les modèles, son effet négatif varie de -0.476 pour les MDC à -0.773 pour les gardiens, reflétant que les qualités athlétiques se déprécient plus rapidement que l'expérience et la lecture du jeu.

Les variables clés diffèrent structurellement selon le poste, ce qui confirme que le marché valorise des compétences radicalement différentes selon le rôle occupé.

6.2 Limites

L'analyse porte uniquement sur la Liga 24/25. Cette restriction garantit l'homogénéité de l'échantillon mais limite la généralisation des résultats, les déterminants de la valeur marchande peuvent différer entre championnats. Un joueur évoluant en Premier League bénéficie par exemple d'une survalorisation liée aux droits TV exceptionnels du championnat anglais, indépendamment de ses performances individuelles.

Le faible effectif de certains groupes comme les milieux défensifs ($n=20$) ou milieux offensifs ($n=24$) constitue une limite statistique importante. Une collecte de données sur plusieurs saisons ou plusieurs championnats permettrait d'obtenir des estimations plus robustes pour ce poste.

Plusieurs variables importantes ne sont pas disponibles dans notre dataset. Cette limite est particulièrement visible pour les postes défensifs et les gardiens, des qualités essentielles comme le positionnement, le leadership, les réflexes ou la gestion de l'équipe ne se traduisent dans aucune statistique quantifiable, ce qui explique en partie les R^2 plus faibles observés pour ces postes.

Nos modèles ne capturent pas les facteurs irrationnels qui influencent pourtant fortement la valeur marchande. La notoriété médiatique d'un joueur peut faire grimper sa valeur bien au-delà de ce que ses statistiques justifient. Le potentiel futur des jeunes joueurs est également très difficile à modéliser. La nationalité joue aussi un rôle, un joueur anglais ou brésilien bénéficie souvent d'une prime de marché liée à l'attrait commercial de sa nationalité. Enfin, appartenir à un grand club comme le Real Madrid ou le FC Barcelone génère une surexposition médiatique qui influence la valeur marchande indépendamment des performances sur le terrain.

6.3 Pistes d'amélioration

Plusieurs pistes peuvent être envisagées pour améliorer ce travail.

L'extension à plusieurs championnats européens permettrait d'augmenter significativement la taille des échantillon et d'introduire des effets fixes de ligue pour contrôler les différences de niveau et de droits TV entre championnats.

L'introduction de données de tracking constituerait une amélioration majeure pour les postes défensifs et les gardiens. Des statistiques comme la vitesse, la distance parcourue, le nombre de sprints ou l'intensité du pressing permettraient de mieux capturer des dimensions de la performance actuellement non quantifiables, ce qui améliorerait significativement les R^2 de ces modèles.

Enfin, étendre l'analyse à plusieurs saisons permettrait de capturer l'évolution de la valeur marchande dans le temps et d'identifier des effets de trajectoire de carrière, un joueur en progression sera valorisé différemment d'un joueur en déclin même à performances égales.